

# Глубокое обучение • Deep Learning

# Структура фазы

## 1 Неделя 🤔

- Введение, 🔥 PyTorch, полносвязные сети, сверточные сети, архитектуры классификации изображений
- Transfer learning, finetuning
- **Проект:** streamlit-приложение для классификации картинок

## 2 Неделя 😓

- Локализация, детекция и сегментация объектов
- **Проект:** streamlit-сервис обнаружения объектов на изображениях

## 3 Неделя 🧐

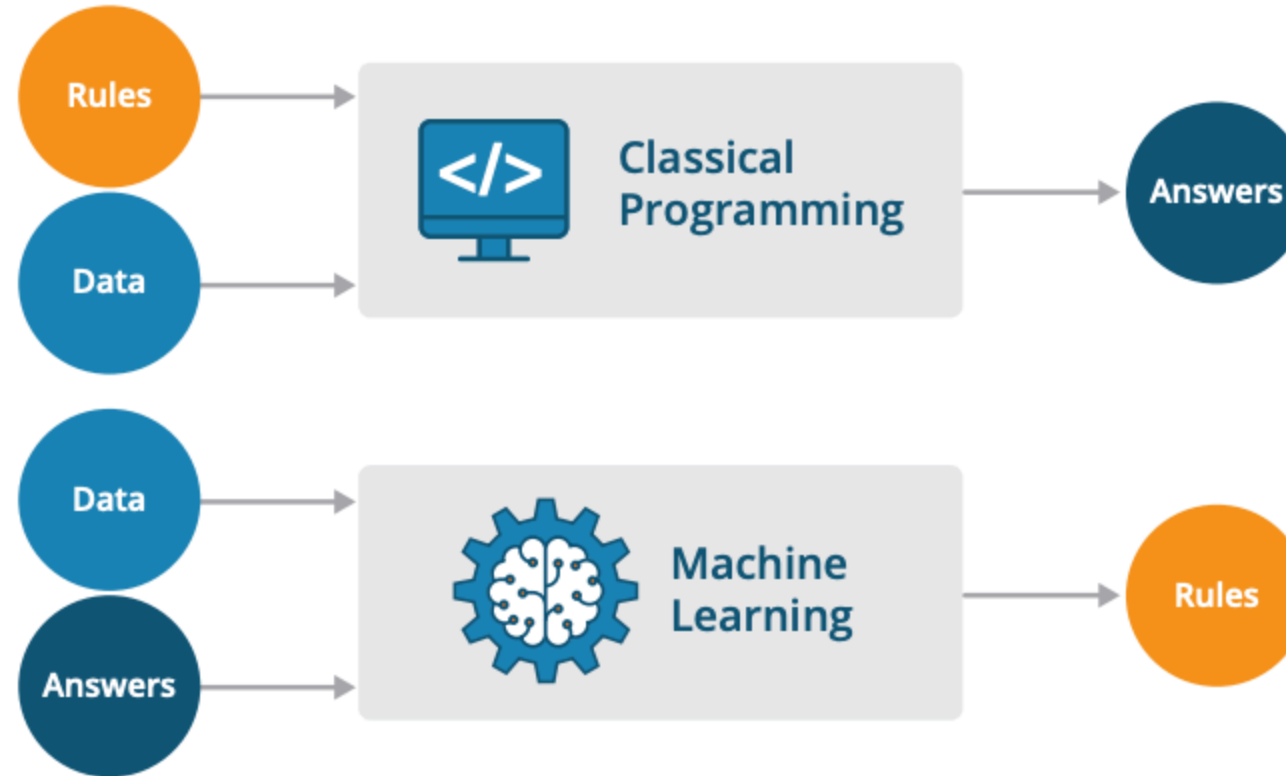
- Нейросетевой подход к обработке текста: рекуррентные сети, трансформеры, BERT и GPT
- **Проект:** классификация пользовательских отзывов, генерация текста

## 4 Неделя 🤖

- Классический и нейросетевой подход в рекомендательных системах (вспомните `pandas` и `matplotlib` )
- **Проект:** семантический поиск

- что такое глубокое обучение?
- интуиция нейронных сетей
- базовая архитектура
- функции активации
- функции потерь

# Глубокое обучение • Deep learning




**Figure 1. Classical programming vs machine learning**

Теперь параметров намного больше

- Архитектура сети • Network Architecture
  - число нейронов, функции активации, регуляризация ...
- Оптимизатор • Optimizer
- Функция потерь • Loss Function
- Инициализация весов • Initial weights

# Структура нейрона



An example of a neuron showing the input ( $x_1 - x_n$ ), their corresponding weights ( $w_1 - w_n$ ), a bias ( $b$ ) and the activation function  $f$  applied to the weighted sum of the inputs.

# Структура нейрона

$$y = f\left(b + \sum_{i=1}^n x_i w_i\right)$$

$b$  - bias - свободный член

$x_i$  - элемент выборки

$w_i$  - обучаемые параметры

$f$  - некоторая функция


Если в качестве функции  $f$  выбрать сигмоиду, во что превратится один нейрон?



## Activation Functions


### Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




### tanh

$$\tanh(x)$$




### ReLU

$$\max(0, x)$$



### Leaky ReLU

$$\max(0.1x, x)$$




### Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$


### ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



`nn.Sigmoid`, `nn.Tanh`, `nn.ReLU`

# Полносвязный слой • Fully Connected • Linear • Dense




🔥 `nn.Linear(in_features, out_features)`

# Полносвязный слой • Fully Connected


Если предположить, что активация везде сигмоида, то такая модель задавалась бы очень просто:

```
model = nn.Sequential(
    nn.Linear(2, 3),
    nn.Sigmoid(),
    nn.Linear(3, 2),
    nn.Sigmoid(),
    nn.Linear(2, 1),
    nn.Sigmoid()
)
```




# Дропаут • Dropout

A neural network before dropout



A neural network after dropout



`nn.Dropout(p)`

# Дропаут • Dropout

Эта операция тоже добавляется просто:

```
model = nn.Sequential(
    nn.Linear(2, 3),
    nn.Dropout(),
    nn.Sigmoid(),
    nn.Linear(3, 2),
    nn.Dropout(),
    nn.Sigmoid(),
    nn.Linear(2, 1),
    nn.Sigmoid()
)
```

А положение относительно активации неважно.

# Функция потерь • Loss

	Задача	Функция потерь	N выходных нейронов
1	Бинарная классификация	Бинарная кросс-энтропия BCELoss ( )	1

# Функция потерь • Loss

	Задача	Функция потерь	Н выходных нейронов
1	Бинарная классификация	Бинарная кросс-энтропия <code>BCELoss()</code>	1
2	Бинарная классификация	Бинарная кросс-энтропия <b>без активации последнего нейрона</b> -> <code>BCEWithLogitsLoss()</code>	1

# Бинарная классификация

Функция потерь - бинарная кросс-энтропия

$y$ – истинные классы	$\hat{p}$ – предсказанные классы	$N$ – объем выборки
-----------------------	----------------------------------	---------------------

$$BCELoss = -\frac{1}{N} \sum_i^N [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]$$

Функция активации - сигмоида

$$\sigma(z) = \frac{1}{1 + \exp^{-z}}$$




```
nn.BCELoss(predictions, targets)
```



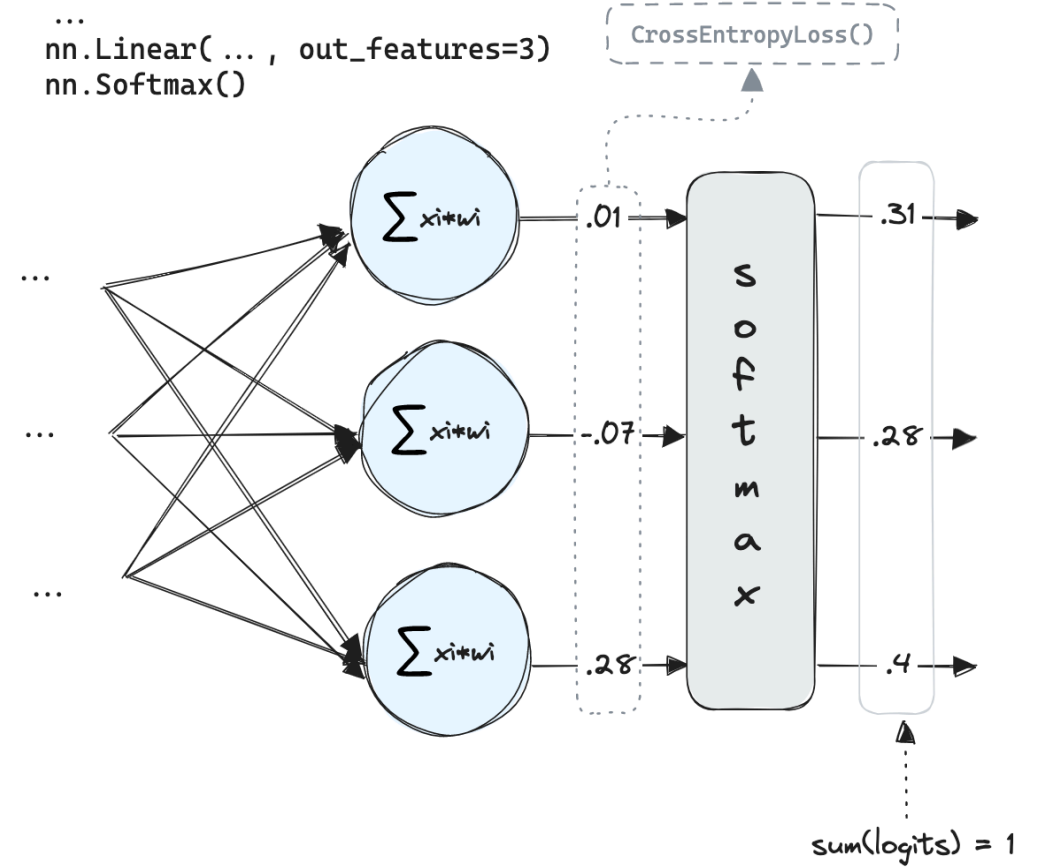
# Функция потерь • Loss

	Задача	Функция потерь	Н выходных нейронов
1	Бинарная классификация	Бинарная кросс-энтропия <code>BCELoss()</code>	1
2	Бинарная классификация	Бинарная кросс-энтропия <b>без активации последнего нейрона</b> -> <code>BCEWithLogitsLoss()</code>	1
3	Многоклассовая классификация	Категориальная кросс-энтропия <code>CrossEntropyLoss()</code>	Н классов

```
...
...
nn.Linear(... , out_features=1)
nn.Sigmoid()
```



```
...
...
nn.Linear(... , out_features=3)
nn.Softmax()
```



# Мультиклассовая классификация

Функция потерь - категориальная кросс-энтропия

$$CELoss = - \sum_i^C y_i \log(\hat{p}_i)$$

Функция для получения вероятностей - **софтмакс** 

$$\sigma(\vec{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

! The input is expected to contain the unnormalized logits for each class (which do not need to be positive or sum to 1, in general) [source](#).

Иначе говоря, чтобы использовать этот лосс, нам не нужно использовать софтмакс. Мы можем его применить, чтобы посмотреть распределение вероятностей **для себя**



```
nn.CrossEntropyLoss(predictions, targets)
```

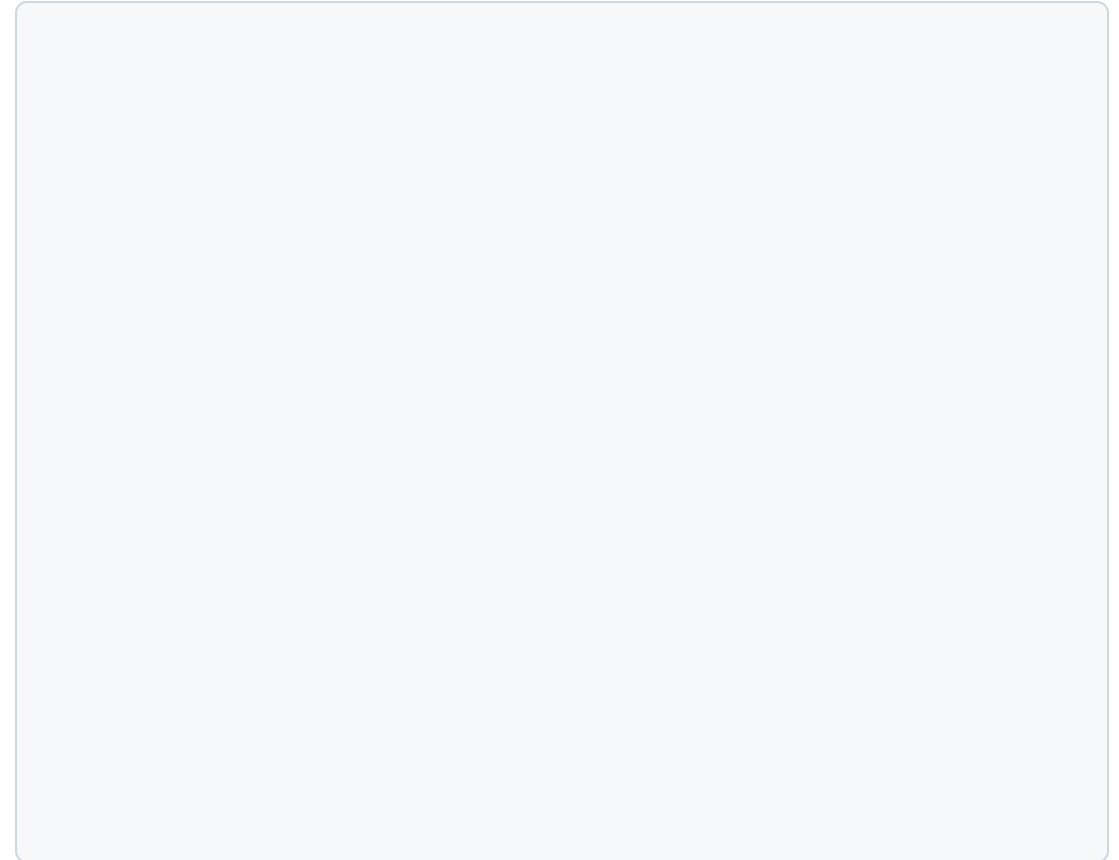
# Мультиклассовая классификация

$$CELoss = - \sum_i^C y_i \log(\hat{p}_i)$$

Три класса: 0, 1, 2

Объект	y	is0?	is1?	is2?
obj_1	2	0	0	1
obj_2	2	0	0	1
obj_3	0	1	0	0
obj_4	1	0	1	0

У сети 3 выхода: для оценка шансов для каждого класса




# Функция потерь • Loss

	Задача	Функция потерь	N выходных нейронов
1	Бинарная классификация	Бинарная кросс-энтропия <code>BCELoss()</code>	1
2	Бинарная классификация	Бинарная кросс-энтропия <b>без активации последнего нейрона</b> -> <code>BCEWithLogitsLoss()</code>	1
3	Многоклассовая классификация	Категориальная кросс-энтропия <code>CrossEntropyLoss()</code>	N классов
4	Регрессия	Любая регрессионная <code>MSELoss()</code> , <code>L1Loss()</code> , etc	1

! Функции потерь, активации и число нейронов выходного слоя 🔥 pytorch losses

# Обратное распространение ошибки



# Инициализация весов

1. Xavier initialization (для гиперболического тангенса)

$$X \sim \mathcal{N}(0, \text{Var}(w_i)) \quad \forall i, \text{Var}(w_i) = \frac{2}{n_{\text{in}} + n_{\text{out}}}$$

2. Normalized Xavier

$$X \sim \mathcal{U}(0, \text{Var}(w_i)) \quad \forall i, \text{Var}(w_i) \sim U \left[ -\frac{\sqrt{6}}{\sqrt{n_{\text{in}} + n_{\text{out}}}}, \frac{\sqrt{6}}{\sqrt{n_{\text{in}} + n_{\text{out}}}} \right].$$

3. He (or Kaiming) initialization (ReLU)

$$\mathcal{N}(0, \frac{2}{n_{\text{in}}})$$

Чаще всего инициализация производится **автоматически!**

## Training loop

# Repeat N epoch

### Training step

Применяем модель как функцию к нашим данным. Выход – какие-то предсказания (preds), которые мы хотим улучшить.

```
1 batch_loss = []
2 batch_metric = []
3 for samples, targets in train_loader:
```

batch  
[samples, targets]

samples

прямой проход  
forward pass

```
1 preds = model(samples)
```

preds

Подсчет функции  
потерь

```
1 loss = criterion(preds, targets)
```

обратный проход  
backward pass

```
1 optimizer.zero_grad()
2 loss.backward()
```

Корректируем  
параметры модели

```
1 optimizer.step()
```

Собираем нужную  
информацию внутри  
одного батча

```
1 batch_loss.append(loss.item())
2 batch_metric.append(some_metric(preds, targets))
```

Применяем модель как функцию к нашим данным. Выход – какие-то предсказания (preds), которые мы хотим улучшить.

Нужно вычислить функцию потерь: насколько мы далеки от настоящих целевых показателей

Вычисляем частные производные параметров: как нужно их скорректировать, чтобы минимизировать функцию потерь?

Применяем вычисленные изменения:  
$$w_{t+1} = w_t - \lambda \frac{\partial L}{\partial w}$$

Для отслеживания процесса обучения собираем текущую информацию о точности модели и значениях функции потерь

### Validation step

С помощью операции model.eval() сообщаем pytorch, но сейчас будет валидировать, а не обучать.

```
1 model.eval()
2 for samples, targets in valid_loader:
```

batch  
[samples, targets]

samples

прямой проход  
forward pass

```
1 with torch.no_grad():
2     preds = model(samples)
```

preds

Подсчет функции  
потерь

```
1 loss = criterion(preds, targets)
```

Собираем нужную  
информацию внутри  
одного батча

```
1 batch_loss.append(loss.item())
2 batch_metric.append(some_metric(preds, targets))
```

targets

В валидационном шаге процесс тот же, но мы не обучаем модель: не считаем частные производные, не обновляем веса. Модель валидируется на данных, которых не было в обучающей выборке



# Шаги обучающего цикла • 1 шаг – обучение

```

for epoch in range(n_epochs):
    # цикл по данным в рамках одной эпохи
    model.train() # переходим в режим обучения
    for data, target in train_loader:

        preds = model(data) # считаем выходы модели – предсказания
        loss = criterion(preds, target) # вычисляем значение функции потерь

        optimizer.zero_grad() # обнуляем градиенты предыдущего шага
        loss.backward() # вычисляем градиенты текущего шага
        optimizer.step() # изменяем значения параметров

        batch_loss.append(loss.item()) # добавляем значение лосса в список
        batch_metric.append(some_metric(preds, target)) # добавляем значение метрики в список

    epoch_train_loss.append(np.mean(batch_loss))
    epoch_train_metric.append(np.mean(batch_metric))

```

## Шаги обучающего цикла • 2 шаг – валидация

```

batch_loss    = []           # обнуляем список значений функции потерь
batch_metric  = []           # обнуляем список значений метрики
# цикл по валидационной части данных
model.eval()  # переходим в режим валидации
for data, target in valid_loader:
    with torch.no_grad():    # градиенты модели не трогаем
        preds = model(data) # считаем выходы модели
        loss = criterion(preds, target) # вычисляем значение функции потерь
        batch_loss.append(loss.item())
        batch_metric.append(some_metric(preds, target))

epoch_valid_loss.append(np.mean(batch_loss))
epoch_valid_metric.append(np.mean(batch_metric))

```

- нейронные сети - гибкий инструмент
- много эвристик и гиперпараметров, архитектура определяется задачей
- полносвязный слой - много параметров
- дропаут - инструмент регуляризации
- функция потерь зависит от задачи, как и всегда